



Администратор Linux

Дисковая подсистема: RAID



Проверить, идет ли запись

Меня хорошо видно && слышно?



Ставим "+", если все хорошо
"-", если есть проблемы



Тема вебинара

Дисковая подсистема: RAID

Андрей Буранов



*Системный администратор в компании VK, департамент VKPlay.
Работаю с операционной системой Linux более 10 лет.
Преподаю на курсах Linux более 8 лет.
Топ-3 лучших преподавателей образовательных порталов.*

*- преподаватель и руководитель курсов
Administrator Linux.Basic
Administrator Linux. Professional
Administrator Linux. Advanced*



Правила вебинара



Активно
участвуем



Off-topic обсуждаем
в учебной группе **#канал
группы**



Задаем вопрос
в чат или голосом



Вопросы вижу в чате,
могу ответить не сразу

Условные обозначения



Индивидуально



Время, необходимое
на активность



Пишем в чат



Говорим голосом



Документ



Ответьте себе или
задайте вопрос

Маршрут вебинара

Дисковая подсистема

Таблицы разделов

RAID`s

mdadm

Практика

Рефлексия



Цели вебинара

К концу занятия вы сможете:

1. Перечислить виды RAID массивов и их отличия.
2. Получить информацию о дисковой подсистеме на любом сервере с ОС Linux.
3. Собрать программный рейд и восстановить его после сбоя.

Дисковая подсистема

Дисковая подсистема

VFS (Virtual File System) – абстрактная файловая система служащая для интерпретации системных вызовов приложений в язык понятный различным файловым системам. Своеобразная унификация.

Самый банальный пример, это когда приложение обращается к локальной и сетевой файловой системе не замечая практической разницы. За него это делает VFS


Дисковая подсистема

Блочные устройства в UNIX и Linux — это устройства хранения с произвольным доступом, над которыми размещаются файловые системы.

Обеспечивает интерфейс к устройству.

```
[root@mdadm ~]$ ls -la /dev/sd*  
brw-rw----. 1 root disk 8, 0 Oct 22 05:32 sda  
brw-rw----. 1 root disk 8, 1 Oct 22 05:32 sda1  
brw-rw----. 1 root disk 8, 2 Oct 22 05:32 sda2  
brw-rw----. 1 root disk 8, 3 Oct 22 05:32 sda3
```

Linux Kernel IO Arch



Дисковая подсистема

Блочное устройство обеспечивает обмен блоками данных.

Блок (chunk) — это единица данных фиксированного размера. Размер блока определяется ядром, но чаще всего он совпадает с размером страницы аппаратной архитектуры, и для 32-битной архитектуры x86 составляет 4096 байт.

```
[root@mdadm ~]$ fdisk -l /dev/sda | grep -i sector
```

```
Disk /dev/sda: 42.9 GB, 42949672960 bytes, 83886080 sectors
```

```
Units = sectors of 1 * 512 = 512 bytes
```

```
Sector size (logical/physical): 512 bytes / 512 bytes
```

Дисковая подсистема

В настоящее время существует **два** подхода к организации **/dev**:

Статическая организация — специальные файлы для всех возможных устройств вне зависимости от того, загружен драйвер соответствующего устройства или нет. Уходящая в прошлое организация.

Динамическая организация — специальные файлы в **/dev** создаются по мере инициализации устройств и загрузки драйверов, и удаляются при выгрузке соответствующего драйвера или удалении устройства.

Процесс работы со статическим **/dev** особых проблем не вызывает – системный администратор при необходимости просто создает

Дисковая подсистема — DevFS

Ядро монтирует к каталогу **/dev** специальную файловую систему, называемую devfs:

- Целиком находится в оперативной памяти;
- Драйвер **devfs** динамически создает специальный файл;
- Динамически же удаляет его.

Дисковая подсистема — Udev

В отличие от **devsfd**, который требовал поддержки со стороны ядра, udev такой поддержки не требует.

- Постоянно закрепленные за устройствами имена, которые не зависят от того, какое положение они занимают в дереве устройств;
- Уведомление внешних по отношению к ядру программ, если устройство было заменено;
- Гибкие правила именования устройств.

Дисковая подсистема — devtmpfs

На текущий момент используется **devtmpfs + udev** (systemd+udev)

После монтирования корневой файловой системы, этот экземпляр tmpfs перемонтируется ядром в каталог /dev

devtmpfs отвечает за заполнение каталога /dev

udev за права доступа, необходимые симлинки и запуск скриптов пользователя

Вопросы?



Ставим “+”,
если вопросы есть



Ставим “-”,
если вопросов нет




Таблицы разделов

Таблицы разделов: MBR

Таблица разделов — логически выделенная часть жесткого диска фиксированного размера видимая ОС как отдельное блочное устройство.

- Физически информация о разделах находится на жестком диске в разных местах в зависимости от типа таблицы.
- Мы будем рассматривать MBR (Master Boot Record) и GPT (Guide Partition Table)

Схема диска в Linux



Таблицы разделов: MBR

ПРЕИМУЩЕСТВА	НЕДОСТАТКИ
+ Самый популярный и совместимый	- Максимум 4 первичных раздела на диске
	- Если первые сектора диска повреждены, диск перестает читаться
	- Максимальный раздел — 2.2 Tb

MBR - Master boot record

Таблицы разделов: MBR

- 512 байт

- Смещение Длина Описание

000h	446	Код загрузчика
1BEh	64	Таблица разделов
	16	Раздел 1
1CEh	16	Раздел 2
1DEh	16	Раздел 3
1EEh	16	Раздел 4
1FEh	2	Сигнатура (55h AAh)



Таблицы разделов: MBR

16 байтный блок раздела

00h	1	Признак активности раздела
01h	1	Начало раздела - головка
02h	1	Начало раздела - сектор (биты 0-5), цилиндр (биты 6,7)
03h	1	Начало раздела - дорожка (старшие биты 8,9 хранятся в байте номера сектора)
04h	1	Код типа раздела
05h	1	Конец раздела - головка
06h	1	Конец раздела - сектор (биты 0-5), цилиндр (биты 6,7)
07h	1	Конец раздела - дорожка (старшие биты 8,9 хранятся в байте номера сектора)
08h	4	Смещение первого сектора
0Ch	4	Количество секторов раздела



Таблицы разделов: MBR

- Backup MBR

```
[root@mdadm ~]$ dd if=/dev/sdX of=/tmp/sda.mbr bs=512 count=1
```

- Восстановление MBR с сохранением таблицы разделов

```
[root@mdadm ~]$ dd if=/tmp/sda.mbr of=/dev/sdb bs=446 count=1
```


- Утилиты для работы

fdisk, sfdisk - создание/удаление 파티ций

Таблицы разделов: GPT или GUID

ПРЕИМУЩЕСТВА	НЕДОСТАТКИ
+ Неограниченное кол-во разделов;	- Не поддерживается старыми системами.
+ Очень большие ограничения на объем;	
+ Раздел зарезервирован, хранятся контрольные CRC-суммы, в случае проблем возможно восстановление.	

Таблицы разделов



Таблицы разделов

- Backup GPT

```
[root@mdadm ~]$ sgdisk --backup=sda.gpt.bkp /dev/sda
```

- Восстановление GPT

```
[root@mdadm ~]$ sgdisk --load-backup=sda.gpt.bkp /dev/sda
```

- Утилиты для работы:

gdisk, sgdisk

Таблицы разделов

Утилиты для работы с
партициями:

- gdisk;
- parted;
- partx;
- partprobe.

Утилиты для работы с
информацией о
железе:

- smartctl;
- hdparm;
- dmesg;
- dmidecode.

Вопросы?



Ставим “+”,
если вопросы есть



Ставим “-”,
если вопросов нет

RAID`S

Задачи стоящие перед дисковой системой

1. Максимальный объем.
2. Максимальная скорость.
3. Максимальная надежность.
4. Минимальная стоимость.

Практически все эти задачи решаются разными уровнями RAID ([Redundant Array of Independent/Inexpensive Disks](#)), но, к сожалению, не все сразу.

Задачи стоящие перед дисковой системой

- Например, RAID-0 дает максимум объема, при отсутствующей надежности, а RAID-1 — максимальную надежность, при отсутствии выигрыша в пространстве.
- В случае RAID-0 и RAID-1 цифра в названии равна вероятности восстановления в случае отказа диска в массиве.
- Но есть и другие уровни RAID — 5,6,10, все это в том или ином виде — компромиссы.

Типы RAID

- Аппаратный — отдельный контроллер со своим процессором, cache, портами, батареей.
- Программный (он же софтверный, он же mdadm) — все через CPU.
- Интегрированный — встроенный в материнскую плату с отдельным чипом для вычисления XOR

Hardware RAID


ПРЕИМУЩЕСТВА	НЕДОСТАТКИ
+ Аппаратное решение, не влияющее на производительность основной системы;	- Высокая стоимость;
+ Выделенный CPU;	- Высокая сложность;
+ Выделенная память для Кэшей;	- Разнообразие интерфейсов управления и драйверов;
+ Возможность использовать BBU (Battery Backup Unit);	- Низкая «мобильность»/переносимость
+ Возможность подключения большого количества дисков;	- Привязка к железу;
+ Прозрачность для загрузчиков (возможность грузиться с любого массива).	- Бóльший простой по времени при аварии;
	- Очень дорогой ремонт, необходимость закупать впрок контроллеры, которые потом могут прекратить выпускать.

Software RAID (mdraid)


ПРЕИМУЩЕСТВА	НЕДОСТАТКИ
+ Бесплатно;	- Отсутствие BBU;
+ Отсутствие привязки к конкретному железу;	- Отсутствие выделенного кэша;
+ Прозрачность конфигурации;	- Отсутствие службы поддержки :-)
+ Примерно одинаковый интерфейс управления в любом linux;	
+ Легкая переносимость между компьютерами;	
+ Гибкость конфигурации.	

RAID - 0

Data
Chunks



RAID-0




$$V_t = V_1 * N$$

RAID - 0


ПРЕИМУЩЕСТВА	НЕДОСТАТКИ
+ Самое быстрое чтение;	- Не «настоящий» RAID, нет отказоустойчивости: отказ одного диска влечет за собой потерю всех данных массива.
+ Очень простой;	
+ Максимальная эффективность использования дискового пространства.	

RAID - 1


Data
Chunks



RAID -1



Disk 1



Disk 2

$$V_t = V_1$$

RAID - 1

ПРЕИМУЩЕСТВА	НЕДОСТАТКИ
+ Простота реализации;	- Высокая стоимость на единицу объема: 100% избыточность.
+ Простота восстановления: перекопировать все данные с «выжившего» диска;	
+ Высокая скорость на чтение.	


XOR

Логическая операция исключающее **ИЛИ** выполняется с двумя битами (a и b). Результат выполнения логической операции **XOR** будет равен 1 (единице), если один из битов a или b равен 1 (единице), во всех остальных случаях, результат равен 0 (нулю).

XOR обладает особенностью, которая даёт возможность заменить любой операнд результатом, и, применив алгоритм хог, получить в результате недостающий операнд.

*Например: $0 \text{ хог } 1 = 1$ (где a, b, c — три диска рейд-массива), в случае если a откажет, мы можем получить его, поставив на его место c и проведя **XOR** между c и b: $1 \text{ хог } 1 = 0$.*

RAID - 5




$$V_t = V_1 * (N - 1)$$

RAID - 5

ПРЕИМУЩЕСТВА	НЕДОСТАТКИ
+ Высокая скорость записи данных;	- Низкая скорость чтения/записи данных малого объема при единичных запросах;
+ Достаточно высокая скорость чтения данных;	- Достаточно сложная реализация;
+ Высокая производительность при большой интенсивности запросов чтения/записи данных;	- Сложное восстановление данных.
+ Малые накладные расходы для реализации избыточности.	

RAID - 6




$$V_t = V_1 * (N - 2)$$

RAID - 6

ПРЕИМУЩЕСТВА	НЕДОСТАТКИ
+ Высокая отказоустойчивость;	- Очень сложная реализация;
+ Достаточно высокая скорость обработки запросов;	- Сложное восстановление данных;
+ Относительно малые накладные расходы для реализации избыточности.	- Очень низкая скорость записи данных.

RAID - 10



$$V_t = V_1 * N / 2$$

RAID - 10

ПРЕИМУЩЕСТВА	НЕДОСТАТКИ
+ Самая высокая отказоустойчивость;	- Двойная стоимость пространства;
+ Самая высокая производительность;	
+ Сочетает в себе преимущества R0 и R1.	



Экзотические RAID

- 1E (запись по очереди в один из дисков, копия в следующий)
- 5+0 (RAID0 из RAID5);
- 5+1 (RAID1 из RAID5);
- 6+0 (RAID0 из RAID6);
- 6+1 (RAID1 из RAID6).

Вопросы?



Ставим “+”,
если вопросы есть



Ставим “-”,
если вопросов нет

mdadm

mdraid: элементы



mdraid: элементы

Блочные устройства:

- разделы;
- диски;
- тома lvm.

Метаданные:

- 0.9, 1.0 - конец устройства (необходимо для загрузки в некоторых случаях);
- 1.1 - начало;
- 1.2 - 4K от начала устройства.


mdraid

Массивы mdraid можно создавать из любых блочных устройств:

- Дисков;
- Разделов;
- Томов lvm.

Наиболее **безопасно** создавать RAID поверх разделов, это может помочь сгладить разный размер дисков, позволит на одном наборе дисков создать разные RAID.

Пример организации дисков



Как использовать mdraid

- Подготовка к созданию, “занулить суперблок”:
mdadm --zero-superblock \$dev_list
- Создание массива:
mdadm --create \$raiddev -l \$level -n \$numdev \$dev_list
- Остановка массива:
mdadm -S \$raiddev
- Информация о массиве:
mdadm --detail \$raiddev
- Генерация данных для конфигурационного файла:
mdadm --examine --scan mdadm --detail --scan

Как использовать mdraid

- Информация о массиве:
cat /proc/mdstat
- Запуск/остановка проверки:
echo (check|idle) > /sys/block/md\${N}/device/action
- Изменение ограничений скорости ребилда:
grep . /proc/sys/dev/raid/speed_limit_m*
/proc/sys/dev/raid/speed_limit_max:200000
/proc/sys/dev/raid/speed_limit_min:1000 # echo 10000 >
/proc/sys/dev/raid/speed_limit_min

mdadm - консоль



Вопросы?



Ставим “+”,
если вопросы есть



Ставим “-”,
если вопросов нет

Домашнее задание: работа с mdadm

1. Добавьте в виртуальную машину несколько дисков
2. Соберите RAID-0/1/5/10 на выбор
3. Сломайте и почините RAID
4. Создайте GPT таблицу, пять разделов и смонтируйте их в системе.



Сроки выполнения:



Рефлексия

Цели вебинара

Проверка достижения целей:

1. Рассказать какие бывают RAID массивы и чем они отличаются
2. Получить информацию о дисковой подсистеме на любом сервере с ОС Linux
3. Описать процесс сборки и восстановления софт рейда

Вопросы для проверки

Что такое VFS и какую функцию она выполняет?

- A. Физическая файловая система для локальных дисков
- B. Утилита для управления разделами дисков
- C. Сетевая файловая система
- D. Абстрактная файловая система, интерпретирующая системные вызовы приложений в команды для разных файловых систем



Отправьте в чат верную букву

Вопросы для проверки

Что такое VFS и какую функцию она выполняет?

A. Физическая файловая система для локальных дисков

B. Утилита для управления разделами дисков

C. Сетевая файловая система

D. Абстрактная файловая система, интерпретирующая системные вызовы приложений в команды для разных файловых систем

Вопросы для проверки

Какой из нижеперечисленных RAID-массивов обеспечивает максимальную скорость чтения, но не обладает отказоустойчивостью?

- A. RAID 0
- B. RAID 1
- C. RAID 5
- D. RAID 6



Отправьте в чат верную букву



Вопросы для проверки

Какой из нижеперечисленных RAID-массивов обеспечивает максимальную скорость чтения, но не обладает отказоустойчивостью?

A. RAID 0

B. RAID 1

C. RAID 5

D. RAID 6

Вопросы для проверки

Какой тип RAID-массива обеспечивает высокую скорость записи данных, но при этом восстановление данных при сбое занимает много времени?

- A. RAID 0
- B. RAID 1
- C. RAID 5
- D. RAID 10



Отправьте в чат верную букву

Вопросы для проверки

Какой тип RAID-массива обеспечивает высокую скорость записи данных, но при этом восстановление данных при сбое занимает много времени?

- A. RAID 0
- B. RAID 1
- C. RAID 5**
- D. RAID 10

Вопросы для проверки

Как называется тип RAID, который полностью управляется процессором компьютера без использования отдельного контроллера?

- A. Аппаратный RAID
- B. Программный RAID
- C. Интегрированный RAID
- D. Аппаратно-программный RAID



Отправьте в чат верную букву

Вопросы для проверки

Как называется тип RAID, который полностью управляется процессором компьютера без использования отдельного контроллера?

A. Аппаратный RAID

B. Программный RAID

C. Интегрированный RAID

D. Аппаратно-программный RAID

Вопросы для проверки

Какой тип RAID-массива считается самым надёжным, поскольку данные сохраняются при выходе из строя одного из дисков?

- A. RAID 0
- B. RAID 1
- C. RAID 5
- D. RAID 6



Отправьте в чат верную букву

Вопросы для проверки

Какой тип RAID-массива считается самым надёжным, поскольку данные сохраняются при выходе из строя одного из дисков?

- A. RAID 0
- B. RAID 1**
- C. RAID 5
- D. RAID 6

Рефлексия



С какими впечатлениями уходите с вебинара?



Как будете применять на практике то, что узнали на вебинаре?

Следующий вебинар



Файловые системы и LVM -1



Ссылка на вебинар
будет в ЛК за 15 минут



Материалы
к занятию в ЛК —
можно изучать



Обязательный материал
обозначен красной
лентой

**Заполните, пожалуйста,
опрос о занятии
по ссылке в чате**

Спасибо за внимание!

Приходите на следующие вебинары!

Андрей Буранов



Системный администратор в компании VK, департамент VKPlay.

Работаю с операционной системой Linux более 10 лет.

Преподаю на курсах Linux более 8 лет.

Топ-3 лучших преподавателей образовательных порталов.

- преподаватель и руководитель курсов

Administrator Linux.Basic

Administrator Linux. Professional

Administrator Linux. Advanced